

# Chap 1 - Estimateurs et Intervalles de confiance

Jordy Palafox

September 28, 2023

**Statistiques Inférentielles**  
CY Tech - Ing 2 GSI 2023-2024



# Motivations

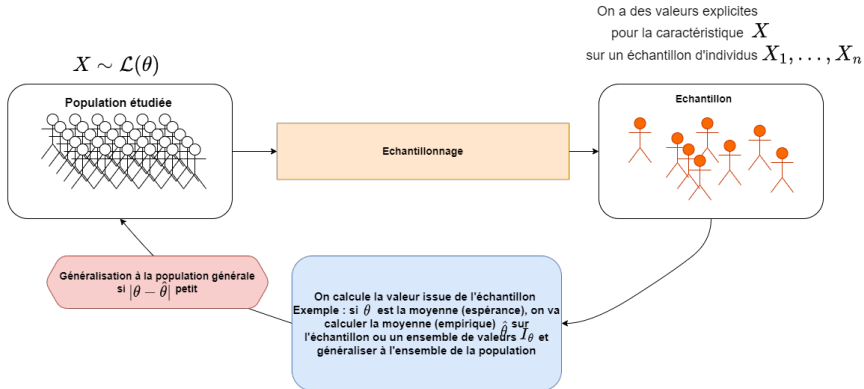
- On s'intéresse à la caractéristique d'une population modélisée par une variable  $X$  donc on connaît la loi (binomiale, exponentielle, gaussienne etc...)
- Cette loi dépend d'un paramètre :
  - 1  $p$  pour la loi binomiale,
  - 2  $\lambda$  pour la loi de Poisson,
  - 3  $\theta$  pour la loi exponentielle,
  - 4  $\mu$  et  $\sigma$  pour la loi normale,
  - 5 ...

## Problème

Ce paramètre est **inconnu**, on va devoir l'évaluer, l'approcher, l'estimer à partir d'un échantillon de la population :

- soit par une valeur estimée (approché)  $\hat{\theta}$ , on parle d'**estimation ponctuelle**,
- soit on se donne un intervalle de valeurs dont on est "sûr" avec un certain niveau de confiance qu'il contient  $\theta$ , on parle d'**intervalle de confiance**.

# En résumé



## Exemple

On s'intéresse au temps d'attente entre deux atterrissages sur un aéroport, modélisé par une variable aléatoire  $X$  qui suit une loi exponentielle :  $X \sim \mathcal{E}(\theta)$ .

On dispose des 9 observations suivantes :

$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$
0.4	1	0.5	0.3	0.1	0.2	1.4	0.2	0.5

**Comment estimer  $\theta$  (qui est inconnu !) ?**

## Définition

Soit  $X$  une variable aléatoire et  $X_1, \dots, X_n$  un échantillon i.i.d. de  $X$  (i.e  $\mathcal{L}_{X_i} \sim \mathcal{L}_X$ ).

- Une **statistique**  $T$  est une v.a. fonction de  $(X_1, \dots, X_n)$  i.e  $T = T(X_1, \dots, X_n)$  dont on observe une réalisation  $t = T(x_1, \dots, x_n)$ .
- Une statistique utilisée pour estimer un paramètre  $\theta$  est appelée **estimateur**, notée souvent  $\hat{\theta}_n$ .

## Exemple suite

Une loi exponentielle  $\mathcal{E}(\theta)$  admet pour espérance et variance (théorique) :

$$\mathbb{E}(X) = \frac{1}{\theta} \text{ et } \mathbb{V}ar(X) = \frac{1}{\theta^2}$$

On peut donc estimer  $\theta$  de deux manières :

- soit par l'**espérance empirique** (estimateur de l'espérance)

$$\bar{X}_n = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \text{ on a donc :}$$

$$\frac{1}{9}(0.4 + 1 + 0.5 + 0.3 + 0.1 + 0.2 + 1.4 + 0.2 + 0.5) = 0.51111$$

- soit par la **variance empirique** (estimateur de la variance)

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \text{ ce qui nous donne (avec } R) 0.181111.$$

**Pourtant à la main on trouve 0.1609877 !**

## Exemple suite

- On trouve  $\bar{x} = 0.511111$ , on trouve  $\hat{\theta} = \frac{1}{\bar{x}} \simeq 1.96$
- Avec la variance empirique, on trouve  $\hat{\theta} = \frac{1}{\bar{x}^2} \simeq 2.35$

## Questions

- Pourquoi la valeur de la variance est différente avec  $R$  du calcul à la main ?
- Quelle est la valeur de  $\hat{\theta}$  à retenir ?

**On va évaluer la qualité des estimateurs !**

# Qualité d'un estimateur

Soit  $\hat{\theta}$  un estimateur du paramètre  $\theta$ , notre objectif est de réduire l'erreur d'estimateur  $|\hat{\theta} - \theta|$ .

## Définition

Le **biais** d'un estimateur  $\hat{\theta}$  du paramètre  $\theta$  est défini par :

$$b(\hat{\theta}) = \mathbb{E}(\hat{\theta} - \theta) = \mathbb{E}(\hat{\theta}) - \theta$$

Un estimateur est dit **sans biais** si  $b(\hat{\theta}) = 0$ , l'erreur moyenne est nulle i.e  $\mathbb{E}(\hat{\theta}) = \theta$ .

## Suite de l'exemple

L'estimateur de la variance  $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$  est biaisé, vérifiez-le!

On préférera la **variance empirique non biaisée**

$$v^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} s^2, \text{ qui est sur } R \text{ (cf data explo!).}$$



## Définition

Le **risque quadratique** d'un estimateur  $\hat{\theta}$  du paramètre  $\theta$  est défini par :

$$R(\hat{\theta}) = \mathbb{E} \left( (\hat{\theta} - \theta)^2 \right).$$

On l'appelle aussi **erreur quadratique moyenne** et on trouvera aussi la notation  $EQM(\hat{\theta})$ .

## Décomposition biais-variance

$$R(\hat{\theta}) = \text{Var}(\hat{\theta}) + b(\hat{\theta})^2.$$

Notion de convergence : a-t-on  $\lim_{n \rightarrow +\infty} \hat{\theta}_n = \theta$  ?

## Définition

Un estimateur est dit **convergent** si  $\lim_{n \rightarrow +\infty} R(\hat{\theta}_n) = 0$ .

Il existe d'autres types de convergences : en probabilité ou presque-sûre qui découlent des lois des grands nombres, **gardez-les à l'esprit!**

## Comment choisir entre deux estimateurs ?

- 1 On garde celui sans biais,
- 2 Puis on garde celui qui a la plus petite variance !

# Exemple de comparaison d'estimateurs

## Application

On considère  $X \sim \mathcal{U}_{[0,\theta]}$  avec  $\theta > 0$  un paramètre inconnu et un échantillon de taille  $n$  de  $X$  :  $X_1, \dots, X_n$ . Soit les trois estimateurs:

$$T_n = 2\bar{X}_n, \quad T'_n = \max(X_1, \dots, X_n) \quad \text{et} \quad T''_n = \frac{n+1}{n} T'_n.$$

On rappelle que  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ .

- ❶ Rappeler l'espérance de  $X$ .
- ❷ Donner la fonction de répartition de  $T'$ , sa densité, l'espérance et la variance.
- ❸ Calculer le biais des estimateurs, que se passe-t-il pour  $n$  grand ?
- ❹ Calculer le risque quadratique .
- ❺ Conclure sur le meilleur estimateur de  $\theta$ .

# Estimateur d'une proportion

Dans le cas d'une **proportion**, on va distinguer une catégorie spécifique parmi la population étudiée. Soit on vérifie le critère soit non : "abimé ou non", "neuf ou non", "jeune ou non" ... C'est donc modélisé par une épreuve de Bernoulli :  $X \sim \mathcal{B}(p)$ . Ici  $p$  est le paramètre à estimer.

L'estimateur usuel d'une proportion est la **fréquence empirique** :

$$F_n = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Biais** :  $b(p) = \mathbb{E}(F_n) - p = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) - p = \frac{1}{n} np - p = 0$ .

C'est un **estimateur sans biais** !

- **Risque empirique** :  $R(F_n) = \mathbb{V}ar(F_n) = \frac{\mathbb{V}ar(X)}{n} = \frac{p(1-p)}{n}$  qui tend vers 0 en  $n \infty$ , donc **convergent**.

# Estimateur d'une moyenne

On a déjà fait le travail ! Résumons :

Soit  $X$  une variable aléatoire de variance  $\sigma^2$  avec  $\mathbb{E}(X) = \mu$  le paramètre à estimer.

L'estimateur de l'espérance est la **moyenne empirique** :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Biais** :  $b(\mu) = \mathbb{E}(\bar{X}_n) - \mu = \mathbb{E}(\frac{1}{n} \sum_{i=1}^n X_i) - \mu = 0$ . C'est un **estimateur sans biais** !
- **Risque quadratique** :  $R(\bar{X}_n) = \mathbb{V}ar(\bar{X}_n) = \frac{\sigma^2}{n}$  qui est aussi **convergent**.

# Estimateur d'une variance

Soit  $X$  une variable aléatoire telle que  $\mathbb{V}ar(X) = \sigma^2$  est le paramètre à estimer.

- L'estimateur usuel de la variance est la **variance empirique**

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2.$$

qui est **biaisé** :  $b(S^2) = \frac{-1}{n+1} \sigma^2$ .

- On utilisera souvent la **variance empirique corrigée**, qui est **sans biais** :

$$S^{*2} = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$


Les deux estimateurs **convergent presque sûrement** mais en moyenne quadratique seulement **dans le cas gaussien**.

# Passons aux intervalles de confiance

## Motivation

On vient de voir comment déterminer une valeur explicite et approchée  $\hat{\theta}$  du paramètre  $\theta$  d'une loi permettant de modéliser un phénomène.

Plutôt que de déterminer une seule valeur  $\hat{\theta}$  on va chercher un ensemble de valeur (**intervalle de confiance**) dont on est presque sûr (**niveau de confiance**) qu'il contient la valeur théorique !




**Intérêt** : l'intervalle de confiance permet de quantifier la probabilité d'erreur dans le choix de l'estimateur.

# Plus concrètement ...

- 1 On a un paramètre (théorique)  $\theta$  d'une loi à estimer.
- 2 On va se fixer un **risque** noté  $\alpha$  qui nous dit : "mon intervalle a 95% de chance de contenir le paramètre".
- 3 On va chercher donc les extrémités  $A$  et  $B$  d'un intervalle tel que  $\mathbb{P}(\theta \in [A, B]) = 1 - \alpha$ .

## Vocabulaire :

- $\alpha$  désigne le **risque**,
- $1 - \alpha$  désigne le **niveau de confiance**.





## En pratique

- On choisit un estimateur  $\hat{\theta}$  de  $\theta$  et on va construire un intervalle **symétrique** en  $\hat{\theta}$  i.e  $A = \hat{\theta} - \ell$  et  $B = \hat{\theta} + \ell$ .
- On se fixe un niveau de risque  $\alpha$  (en général 1, 2.5, 5%)
- On a donc :

$$\begin{aligned}\mathbb{P}(\hat{\theta} - \ell \leq \theta \leq \hat{\theta} + \ell) &= \mathbb{P}(\theta - \ell \leq \hat{\theta} \leq \theta + \ell) \\ &= 1 - \alpha.\end{aligned}$$

- On détermine alors  $\ell$  grâce à la table de la loi de l'estimateur  $\hat{\theta}$ .

# Les cas rencontrés

## Intervalle de confiance : 3 types de paramètre

IDC d'une proportion

X suit une loi de Bernouilli et n grand  
( $n > 30$ )

IDC d'une moyenne

**Variance connue** : X est gaussien ou n grand

**Variance inconnue** :  
- X gaussien et n petit ( $\leq 30$ )  
- X non gaussien et n assez grand ( $> 30$ )

IDC d'une variance

**Moyenne connue**

**Moyenne inconnue**

# IDC d'une proportion $p$

Supposons que  $X \sim \mathcal{B}(p)$  et que l'échantillon est suffisamment grand i.e  $n > 30$ . On va utiliser l'estimateur empirique de la fréquence  $F_n = \frac{1}{n} \sum_{i=1}^n X_i$  pour approcher  $p$  :

## Procédure

- 1 On commence par remarquer que comme  $n > 30$ , on peut utiliser le TCL :  $Z = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} = \frac{F_n - p}{\sqrt{p(1-p)}} \sqrt{n} \sim \mathcal{N}(0, 1)$ .
- 2 On se fixe un risque  $\alpha$  tel que  $\mathbb{P}(-t_\alpha \leq Z \leq t_\alpha) = 1 - \alpha$
- 3 Il suffit de lire le quantile  $t_\alpha$  associé à la probabilité  $1 - \alpha$  dans la table de la loi  $\mathcal{N}(0, 1)$ .
- 4 Bien remarquer que on a un IDC sur  $Z$ , il faut donc isoler  $p$  :

$$\begin{aligned} 1 - \alpha &= \mathbb{P}(-t_\alpha \leq Z \leq t_\alpha) \\ &= \mathbb{P}\left(-t_\alpha \leq \frac{F_n - p}{\sqrt{p(1-p)}} \sqrt{p} \leq t_\alpha\right) \end{aligned}$$

## Procédure

4

$$= \mathbb{P} \left( F_n - t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} \leq p \leq F_n + t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right)$$

5

On obtient l'IDC :

$$[A, B] = \left[ F_n - t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}}, F_n + t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

6

On remarque que l'IDC de  $p$  dépend de  $p$  lui-même, on va donc estimer  $F_n$  sur l'échantillon et on remplace par la valeur estimée  $f_n$  dans l'IDC :

$$[a, b] = \left[ f_n - t_\alpha \frac{\sqrt{f_n(1-f_n)}}{\sqrt{n}}, f_n + t_\alpha \frac{\sqrt{f_n(1-f_n)}}{\sqrt{n}} \right]$$

## Enoncé

On dispose d'un échantillon de 503 pommes mais 47 sont abîmées. Déterminer un intervalle de confiance de la proportion de pommes abîmées sur l'ensemble du verger.



- 1 On considère  $X \sim \mathcal{B}(p)$  où  $X$  modélise : la pomme est-elle abîmée ou non. De plus l'échantillon est assez grand ( $503 > 30$ ) donc on est dans les hypothèses de la procédure.
- 2 On va commencer par calculer la proportion de pommes abîmées observée  $f_n = \frac{47}{503} \simeq 0.09343936 = 9.343936\%$ .
- 3 Fixons nous un risque  $\alpha = 5\%$ . Ainsi le quantile  $t_\alpha = 1.96$  d'après la table de la loi  $\mathcal{N}(0, 1)$ .
- 4 Alors l'IDC de  $p$  est :

$$[a, b] = [6.800412\%, 11.88746\%]$$

## Conclusion

La proportion de pommes abîmées dans le verger est donc est 6.8% et 11.88% avec un risque d'erreur de 5% (ou une confiance de 95%)

# IDC pour une moyenne, variance $\sigma^2$ connue

$X$  suit une loi gaussienne  $\mathcal{N}(\mu, \sigma^2)$  ou  $n$  grand ( $n > 30$ )

On utilise l'estimateur  $\bar{X}_n$  estimateur de  $\mu$  et  $\sigma^2$  est connue (on a une valeur explicite).

## Procédure

- 1 On considère  $\bar{X}_n \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$  ou de manière équivalente  $\frac{\bar{X}_n - \mu}{\sigma} \sqrt{n} \sim \mathcal{N}(0, 1)$  (**Démontrer le**)
- 2 Il suffit de lire sur la table de  $\mathcal{N}(0, 1)$  le quantile  $t_\alpha$  tel que  $\mathbb{P}(-t_\alpha \leq Z \leq t_\alpha) = 1 - \alpha$ .
- 3 On a ainsi :

$$\begin{aligned} 1 - \alpha &= \mathbb{P}(-t_\alpha \leq Z \leq t_\alpha) \\ &= \mathbb{P}\left(-t_\alpha \leq \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n} \leq t_\alpha\right) \end{aligned}$$

## Procédure

③ Ainsi :

$$1 - \alpha = \mathbb{P} \left( \bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} \leq \mu \leq +t_\alpha \frac{\sigma}{\sqrt{n}} \right)$$

④ On obtient finalement l'IDC :

$$[a, b] = \left[ \bar{x}_n - t_\alpha \frac{\sigma}{\sqrt{n}}, \bar{x}_n + t_\alpha \frac{\sigma}{\sqrt{n}} \right]$$



## Exercice

Une société fabrique des câbles d'acier dont on souhaite étudier la résistance moyenne de rupture. Au vue de l'utilisation des câbles, la résistance doit avoir un écart-type  $\sigma = 25\text{kg}$ .

On dispose d'un échantillon de 100 câbles sur lequel on observe une résistance moyenne  $\bar{x}$  de 2630 kg.

Déterminons un intervalle de confiance de la résistance moyenne de rupture  $\mu$  avec un risque 2.5%.

- 1 L'échantillon est assez grand ( $n > 30$ ). On considère donc  $\overline{X}_n \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$  donc  $\frac{\overline{X}_n - \mu}{\sigma} \sqrt{n} \sim \mathcal{N}(0, 1)$ .
- 2 On cherche  $t_\alpha$  tel que :

$$\begin{aligned} 0.975 &= \mathbb{P}(-t_\alpha \leq Z \leq t_\alpha) \\ &= F_Z(t_\alpha) - F_Z(-t_\alpha) \\ &= 2F_Z(t_\alpha) - 1. \end{aligned}$$

D'où  $F_Z(t_\alpha) = 0.9875$  et par la table  $\mathcal{N}(0, 1)$  on a  $t_\alpha = 2.241403$ .

On peut maintenant déterminer l'IDC.

# IDC pour une moyenne, variance $\sigma^2$ inconnue, $n$ petit

$X$  suit une loi gaussienne  $\mathcal{N}(\mu, \sigma^2)$  et  $n$  petit ( $n \leq 30$ )

On a toujours  $\frac{1}{n} \sum_{i=1}^n X_i$  estimateur de  $\mu = \mathbb{E}(X)$  et  $\sigma^2 = \mathbb{V}ar(X)$ .

Procédure (c'est toujours la même chose)

- 1 On utilise  $S^{*2}$  (la variance empirique non biaisée) au lieu de  $\sigma^2$  (inconnue !),
- 2 On pose  $Y = \frac{\bar{X}_n - \mu}{S^*} \sqrt{n}$  telle que  $Y \sim \mathcal{T}_{n-1}$  loi de Student à  $n - 1$  degré de liberté.
- 3 La table de  $\mathcal{T}_{n-1}$  donne  $t_\alpha$  tel que  $\mathbb{P}(-t_\alpha \leq Y \leq t_\alpha) = 1 - \alpha$ ,
- 4 En transformant l'expression de sorte à encadrer  $\mu$  on obtient l'IDC :

$$[a, b] = \left[ \bar{x}_n - t \frac{s^*}{\sqrt{n}}, \bar{x}_n + t \frac{s^*}{\sqrt{n}} \right]$$

# IDC pour une moyenne, variance $\sigma^2$ inconnue, $n$ grand

$X$  est non gaussien et  $n$  assez grand ( $n > 30$ )

On a encore et toujours  $\frac{1}{n} \sum_{i=1}^n X_i$  estimateur de  $\mu = \mathbb{E}(X)$  et  $\sigma^2 = \text{Var}(X)$ .

Procédure (c'est toujours la même chose)

- 1 On utilise  $S^{*2}$  (la variance empirique non biaisée) au lieu de  $\sigma^2$  (inconnue !),
- 2 On pose  $Y = \frac{\bar{X}_n - \mu}{S^*} \sqrt{n}$  telle que  $Y \sim \mathcal{N}(0, 1)$ .
- 3 La table de  $\mathcal{N}(0, 1)$  donne  $t_\alpha$  tel que  $\mathbb{P}(-t_\alpha \leq Y \leq t_\alpha) = 1 - \alpha$ ,
- 4 En transformant l'expression de sorte à encadrer  $\mu$  on obtient l'IDC :

$$[a, b] = \left[ \bar{x}_n - t \frac{s^*}{\sqrt{n}}, \bar{x}_n + t \frac{s^*}{\sqrt{n}} \right]$$

# IDC pour une variance, $\mu$ connue ou inconnue

$X$  suit une loi  $\mathcal{N}(\mu, \sigma^2)$

## Espérance $\mu$ connue

- 1 On utilise l'estimateur  $\mathbb{V}ar_1 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ .
- 2 On a  $n \frac{\mathbb{V}ar_1}{\sigma^2} \sim \chi_n^2$ .

## Espérance $\mu$ inconnue

- 1 On utilise l'estimateur  $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$  ou  $S^{*2} = \frac{n}{n-1} S^2$
- 2 On a  $n \frac{S^2}{\sigma^2} = (n-1) \frac{S^{*2}}{\sigma^2} \sim \chi_{n-1}^2$ .

Dans les deux cas, c'est la lecture de la table bien choisie qui donne les valeurs de  $t_\alpha$  et donc de définir l'IDC.

## Exercice

On s'intéresse à la taille des étudiants de CY Tech, sur le campus paloï. Mais on ne connaît ni l'espérance théorique ni la variance, seulement que la taille  $X$  suit une loi gaussienne !

Un échantillon de 25 personnes parmi les ING2 GSI donne les mesures suivantes :

$$\bar{x} = 177.1cm \text{ et } s^* = 3.8$$

Donner un IDC à 95% de confiance de la variance  $\sigma^2$ .

- ① D'après ce qu'il précède,  $(n-1)\frac{S^{*2}}{\sigma^2} \sim \chi_{n-1}^2$  donc  $Y = 24\frac{S^{*2}}{\sigma^2} \sim \chi_{24}^2$ .
- ② D'après la table de la loi  $\chi_{24}^2$  on a  $t_1 = 12.4$  tel que  $0.025 = \mathbb{P}(Y \leq t_1)$ ,
- ③ La même table donne  $t_2 = 39.36$  tel que  $0.975 = \mathbb{P}(Y \leq t_2)$ .
- ④ On en déduit  $0.95 = \mathbb{P}(12.4 \leq Y \leq 39.36)$ .
- ⑤ Après quelques étapes on obtient finalement  $0.95 = \mathbb{P}(8.8 \leq \sigma^2 \leq 27.9)$ .  
Autrement dit l'IDC est  $[8.8, 27.9]$ .

# Mais pourquoi ?



D'où viennent toutes ces lois et les choix de  $n$  ou  $n - 1$  ?  
Ces choix de lois découlent du **théorème de Cochran**



# Enoncé du théorème de Cochran et conséquences

## Théorème de Cochran

Soit  $X = (X_1, \dots, X_n)^t$  un vecteur gaussien centré réduit. Pour  $F$  un sous-espace vectoriel de  $\mathbb{R}^n$  de dimension  $p$ , on note  $P_F$  (resp  $P_{F^\perp}$ ) la projection orthogonale sur  $F$  (resp  $F^\perp$ ).

Alors les vecteurs  $P_F X$  et  $P_{F^\perp} X$  sont gaussiens, indépendants, de lois :

$$P_F X \sim \mathcal{N}(0, P_F) \text{ et } P_{F^\perp} X \sim \mathcal{N}(0, P_{F^\perp}).$$

De plus, les variables  $\|P_F X\|^2$  et  $\|P_{F^\perp} X\|^2$  sont gaussiens, indépendants, de lois :

$$\|P_F X\|^2 \sim \chi_p^2 \text{ et } \|P_{F^\perp} X\|^2 \sim \chi_{n-p}^2.$$

## Corollaire de Cochran

On a :  $\overline{X_n} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$ ,  $(n-1) \frac{S_n^2}{\sigma^2} \sim \chi_{n-1}^2$  et  $\sqrt{n} \frac{\overline{X_n} - \mu}{\sigma} \sim \mathcal{T}_{n-1}$ .

- ❶ Le corollaire de Cochran se démontre en utilisant des manipulations proches de celles réalisées en data explo ! Voir <https://perso.univ-rennes1.fr/jean-christophe.breton/agreg/AGREG/COURS/cochran.pdf>
- ❷ Cela explique à la fois le choix des lois et les degrés de liberté.
- ❸ Non, ce n'est pas à connaître, c'est pour votre culture.

## A retenir

Si on remplace une valeur théorique par sa valeur estimée sur l'échantillon, on perd un degré de liberté par valeur.